

Lightweight Edge-Preserving Joint Enhancement-Compression Network for Extreme Low-Light Environments

CUAI 9기 CV 4팀

노재혁(AI학과), 인선우(전자전기공학부)

[요약] 저조도 영상은 압축 시 노이즈에 비트가 낭비되고 구조가 손실된다. 본 연구는 CompressAI hyperprior에 CBAM과 Sobel 기반 Edge Loss, Total Variation Loss를 결합해 저조도 향상과 압축을 동시 학습하는 모델을 제안한다. LOL eval15에서 인공 노이즈 학습 방식은 성능이 오히려 하락했고, 제안 모델은 유사 비트레이트에서 SSIM 0.723에서 0.741로 개선되었다.

1. 서론

학습 기반 이미지 압축은 Ballé 등이 제안한 hyperprior 구조[1] 이후 전통적 코덱을 상회하는 Rate-Distortion, RD 성능을 보여 왔다. 그러나 이러한 모델은 대체로 정상 조도에서 촬영된 깨끗한 영상을 전제로 설계된다. 실제 야간 감시 카메라나 블랙박스처럼 조도가 극도로 낮은 환경에서 촬영된 영상은 신호 대 잡음비가 낮아, 압축기가 정작 보존해야 할 구조 정보 대신 센서 노이즈를 부호화하는 데 비트를 소모하는 문제가 발생한다.

이를 해결하기 위해 Cheng 등은 압축과 노이즈 제거를 함께 학습하는 JDC(Joint Denoising and Compression) 구조를 제안했다[2]. 다만 이 접근은 학습 시 깨끗한 영상에 인공 가우시안 노이즈(AWGN)를 합성해 입력을 만든다. 이후 연구는 인공 노이즈의 한계를 인식해 실제 카메라 센서 노이즈 도메인으로 옮겨가고 있고[3], 학습 기반 압축기가 노이즈가 심한 실제 영상에서 복원 성능이 급격히 저하된다는 분석도 보고되었다[4]. 그러나 이들 역시 과제를 노이즈 제거로 한정하며, 빛 자체가 부족해 밝기가 소실된 극저조도 환경은 다루지 않는다. 실제 저조도 영상의 열화는 노이즈만이 아니라 밝기 자체의 소실을 동반하므로, AWGN 가정으로 학습된 모델이 실

제 야간 영상에 그대로 적용될 수 있는지는 검증이 필요하다.

본 연구는 이 간극을 실증적으로 확인하고, 저조도 향상(low-light enhancement)과 압축을 하나의 목적 함수 안에서 동시에 최적화하는 파이프라인을 제안한다. 구체적인 기여는 다음과 같다. 첫째, AWGN 기반 JDC가 실제 저조도 영상에서 학습하지 않은 모델보다도 낮은 성능을 보이는 도메인 시프트 현상을 정량적으로 보인다. 둘째, hyperprior 디코더에 CBAM[5] 주의 집중 모듈을 잔차 형태로 이식하고, Sobel 연산 기반의 Edge Loss와 Total Variation(TV) Loss를 RD 손실에 결합해 저비트레이트에서 윤곽 구조가 뭉개지는 현상을 완화한다.

2. 본론

1) 문제 정의 및 베이스라인 설계

본 연구의 과제는 저조도 입력을 받아, 정상 조도의 정답 영상에 가까운 복원 결과를 최소한의 비트로 전송하는 것이다. 즉 입력과 목표의 조도가 다르다는 점에서, 입력과 목표가 같은 조도인 일반적인 압축이나 JDC 문제와 구별된다.

제안 방법의 기여를 분리해 확인하기 위해 다음 네 가지 설정을 비교했다.

- Baseline 1: 사전학습된 CompressAI hyperprior를 학습 없이 그대로 적용. 저조도 입력에 대한 기존 압축기의 한계를 보인다.
- Baseline 2: 정상 조도 영상에 표준편차 25/255의 AWGN을 합성해 입력으로 쓰고 노이즈 제거와 압축을 동시 학습. 기존 JDC 방식[2]의 재현에 해당한다.

· Baseline 3: LOL 데이터셋[6]의 실제 저조도-정상 조도 쌍으로 순수 RD 손실만 사용해 미세조정.

· Ours: Baseline 3에 CBAM과 Edge/TV Loss를 추가한 최종 모델.

2) 제안 모델 구조

기본 모델은 CompressAI[7]의 bmsbj2018_hyperprior이다. 저조도 영상에서는 잠재 표현의 채널별·공간별 정보량 편차가 크다고 보고, 양자화된 잠재 변수에 CBAM을 적용해 중요한 채널과 영역을 선택적으로 강조했다. 사전학습 가중치를 훼손하지 않도록 아래와 같이 학습 가능한 스칼라 α 를 둔 잔차 형태로 결합하고, α 를 0.01로 초기화해 warm-up이 가능하도록 했다.

$$\hat{y}' = \hat{y} + \alpha \cdot \text{CBAM}(\hat{y})$$

CBAM은 채널 주의(전역 평균/최대 풀링 후 공유 MLP)와 공간 주의(채널축 평균/최대 연결 후 7×7 합성곱)를 순차 적용한다. 삽입 위치는 인코더와 디코더를 모두 검토했으며, 최종적으로 엔트로피 복호 직후의 디코더 입력단을 채택했다.

3) 손실 함수 설계

최종 손실은 RD 항에 두 개의 정규화 항을 더한 형태이다.

$$L = R_{\text{bpp}} + \lambda \cdot 255^2 \cdot \text{MSE} + \beta \cdot L_{\text{edge}} + \gamma \cdot L_{\text{TV}}$$

L_{edge} 는 Sobel 커널로 계산한 그래디언트 크기 맵의 L1 거리이다. BT.601 휘도 채널에서 엣지를 추출해 구조 정보에만 집중하도록 했다.

$$L_{\text{edge}} = \|E(\hat{x}) - E(x)\|_1, E(I) = \sqrt{(Gx^2 + Gy^2 + \varepsilon)}$$

설계 과정에서 세 가지 문제를 확인하고 수정했다. 첫째, MSE 항의 실효 계수가 $\lambda \cdot 255^2 \approx 227.6$ 으로 지배적이어서, 초기에 설정한 $\beta=0.05 \sim 0.1$ 에서는 Edge 항의 기여가 무시할 수준에 머물렀다. 이에 β 를 0.05에서 40까지 단계적으로 키우는 격자 탐색을 수행해 동작 범위를 정했다. 둘째, 초기 실험에서 격자 형태의 체커보드 아티팩트가 관찰되어, 인접 픽셀 차분의 절대값 평균으로 정의되는 TV Loss를 추가해 이를 억제했다. 셋째, 초기 설계에서는 LOL 쌍의 1~3화소 정합 오차를 흡수할 목적으로 Sobel 엣지 맵과 MSE 항에 가우시안 블러를 적용

했으나, TV Loss 도입 이후 과평활화가 심해져 최종 구성에서는 두 블러를 모두 비활성화했다.

다만 Edge Loss는 고주파를 살리는 방향으로, TV Loss는 고주파를 누르는 방향으로 작용하므로 두 항은 서로 상충한다. 본 실험에서는 격자 탐색 결과를 바탕으로 $\beta=20$, $\gamma=40$ 을 채택했으며, 이 값은 뒤의 모든 quality index에 동일하게 적용해 동작점 간 비교가 가중치 차이에 오염되지 않도록 했다.

4) 실험 설정

데이터셋은 LOL[6]을 사용했다. 학습에는 our485(485쌍), 평가에는 학습에 사용하지 않은 eval15(15쌍)를 썼다. 학습 시에는 256×256 무작위 크롭과 50% 확률의 좌우 반전을 저조도/정상 조도 쌍에 동일하게 적용했다. 최적화는 Adam(주 가중치 $lr=1e-4$, 엔트로피 파라미터 $lr=1e-3$)를 사용했고, quality index 2, 4, 6, 8에 대해 각각 독립적으로 300 epoch 학습했다. 제안 모델은 네 동작점 모두 $\beta=20$, $\gamma=40$ (Baseline 3은 $\beta=\gamma=0$)으로 동일하게 두어 가중치 조건을 통일했다. 다만 λ 는 네 동작점 모두 0.0035로 고정했는데, 이는 CompressAI가 quality index 2에 대응시키는 값이다. 상위 index에 대응하는 λ (각각 0.0130, 0.0483, 0.18)를 적용하지 않았으므로, index가 커질수록 손실 함수가 상정하는 RD 균형점과 사전학습 가중치의 동작점이 어긋난다.

평가는 크롭 없이 원본 해상도에서 수행했다. 모델 입력 제약을 맞추기 위해 가로·세로를 64의 배수가 되도록 반사 패딩한 뒤, 지표 계산 시에는 패딩 영역을 다시 잘라내고 BPP도 원본 픽셀 수로 나누었다. PSNR과 SSIM은 torchmetrics 구현을 사용했다.

5) 결과 및 분석

표 1. LOL eval15 정량 평가 결과 (quality index 2, 제안 모델은 $\beta=20$, $\gamma=40$)

모델	BPP	PSNR(dB)	SSIM
Baseline 1	0.054	7.81	0.196
Baseline 2	0.053	7.28	0.106
Baseline 3	0.194	18.06	0.714
Ours	0.287	18.10	0.741

표 1은 quality index 2에서의 결과이다. 가장 두드러지는 결과는 Baseline 2가 학습을 전혀 하지 않은 Baseline 1보다도 낫다는 점이다. PSNR은 7.81 dB에서 7.28 dB

로, SSIM은 0.196에서 0.106으로 오히려 하락했다. AWGN으로 학습된 디노이저가 실제 저조도 영상의 열화 특성과 맞지 않아, 신호로 보아야 할 어두운 영역의 미세 구조까지 노이즈로 간주해 제거한 것으로 해석된다. 이는 기존 JDC 방식의 노이즈 가정이 실제 야간 환경에 그대로 이전되지 않음을 보여준다.

반면 실제 저조도 쌍으로 학습한 Baseline 3은 PSNR 18.06 dB, SSIM 0.714로 약 10 dB의 도약을 보였다. 저조도 환경에서는 노이즈 제거보다 밝기 복원 자체가 지배적인 요인임을 시사한다.




그림 1. LOL eval15 BPP-PSNR RD 곡선




그림 2. LOL eval15 BPP-SSIM RD 곡선

그림 1과 그림 2는 quality index 2, 4, 6, 8에 대한 RD 곡선이며, 동작점별 수치는 표 2와 같다. SSIM 기준으로 제안 모델은 네 동작점 모두에서 Baseline 3을 상회했고, 그 차이는 +0.011에서 +0.034 사이로 일관되게 나타났다. 표 2의 모든 제안 모델 항목은 $\beta=20$, $\gamma=40$ 이라는 동일한 가중치로 학습된 것이므로, 이 차이는 가중치 설정의 차이가 아니라 동작점에 따른 것이다. 이는 Edge Loss가 의도한 대로 구조 유사도 보존에 기여했음을 뒷받침한다.

표 2. quality index별 Baseline 3과 제안 모델 비교 (제안 모델은 네 동작점 모두 $\beta=20$, $\gamma=40$)

모델 (quality)	BPP	PSNR(dB)	SSIM
Baseline 3 (Q2)	0.194	18.06	0.714
Ours (Q2)	0.287	18.10	0.741
Baseline 3 (Q4)	0.229	17.71	0.719
Ours (Q4)	0.324	17.69	0.741
Baseline 3 (Q6)	0.263	17.67	0.722
Ours (Q6)	0.370	17.28	0.732
Baseline 3 (Q8)	0.328	17.90	0.723
Ours (Q8)	0.465	19.77	0.757

표 3. 유사 비트레이트 조건에서의 비교 (제안 모델은 $\beta=20$, $\gamma=40$)

모델	BPP	PSNR(dB)	SSIM
Baseline 3 (Q8)	0.328	17.90	0.723
Ours (Q2)	0.287	18.10	0.741

다만 동일 quality index에서 제안 모델의 비트레이트는 Baseline 3 대비 40~48% 높다. Edge/TV 항이 고주파 성분을 유지하도록 유도하면서 잡재 표현의 엔트로피가 증가한 결과로 보인다. 따라서 비트레이트를 맞춰 대조하면, 표 3과 같이 제안 모델(Q2, 0.287 BPP)이 Baseline 3(Q8, 0.328 BPP) 대비 12.7% 적은 비트로 PSNR +0.20 dB, SSIM +0.018을 달성한다.

한편 PSNR 곡선은 비단조적이다. quality index 6에서는 제안 모델이 Baseline 3보다 0.39 dB 낮은 반면, index 8에서는 1.86 dB 높다. 가장 유력한 원인은 β 와 γ 를 네 동작점에 동일하게 고정한 데 있다. 격자 탐색이 비트레이트에 여유가 있는 고품질 구간을 기준으로 이뤄졌으므로, $\beta=20$, $\gamma=40$ 은 고비트레이트 환경에 편향된 설정이다. 비트가 제한된 중간 구간에서는 픽셀 단위 MSE를 줄이려는 방향과 엣지를 강화하려는 방향이 경쟁하는 perception-distortion 상충이 두드러져, 엣지를 살리려는 힘이 오히려 PSNR을 떨어뜨린다. 여기에 실험 설정에서 언급한 λ 고정도 더해진다. 네 동작점 모두 quality index 2에 해당하는 $\lambda=0.0035$ 를 사용했으므로 index가 커질수록 손실이 상정하는 RD 균형점과 실제 동작점의 괴리가 커지며, 이 괴리는 Baseline 3에도 동일하게 작용하지만 Edge/TV 항이 추가된 제안 모델에서 더 크게 증폭될 수 있다. 현 단계의 결과는 SSIM 개선은 일관되나, PSNR 개선은 아직 안정적이라고 주장하기 어렵다.

표 4. 모델 크기 비교 (파라미터 수, 자체 실측 및 선행연구 인

용)

모델	파라미터 수	비고
TCM (CVPR 2023)[8]	45.2M - 76.6M	범용 고화질 목적, 저조도 특화가 아니며 옛지 디바이스·실시간 처리에 부적합
Joint-IC-LL (AAAI 2024)[9]	~30M	저조도 개선과 압축을 동시 수행하나 구조가 무거움
Baseline 3 (bmshj2018)	5.08M / 11.82M	가볍지만 극저조도 환경을 반영하지 못함
Ours	5.08M / 11.83M	기반 모델과 사실상 동일한 크기로 개선 달성

제안 방법의 실용성은 모델 크기에서 드러난다. 표 4와 같이 최근 고성능 압축 모델이 수천만 개 규모의 파라미터를 사용하는 것과 달리, 제안 모델은 기반 모델과 사실상 동일한 크기를 유지한다. CBAM 이식으로 늘어난 파라미터는 quality index 2와 4에서 4,707개, 6과 8에서 12,899개로 각각 전체의 0.09%, 0.11%에 지나지 않는다. 즉 관측된 SSIM 개선은 모델을 키워서 얻은 것이 아니라 주의 집중 모듈과 손실 함수 설계에서 온 것이며, 이는 옛지 디바이스 탑재를 전제로 하는 야간 CCTV나 드론 환경에서 의미가 있다.

3. 결론

본 연구는 저조도 환경에서의 압축 문제를 노이즈 제거가 아닌 저조도 향상과 압축의 동시 최적화 문제로 재정의하고, 이를 위한 파이프라인을 구현·검증했다.

핵심 결과는 두 가지이다. 첫째, 인공 가우시안 노이즈로 학습한 기존 JDC 방식은 실제 저조도 영상에서 PSNR 7.28 dB, SSIM 0.106으로 학습하지 않은 모델(7.81 dB, 0.196)보다도 낮은 성능을 보였다. 노이즈 모델의 도메인 시프트가 실제 성능 저하로 이어짐을 확인했다. 둘째, 실제 저조도 쌍 학습에 CBAM과 Edge/TV Loss를 결합한 제안 모델은 SSIM을 전 동작점에서 일관되게 개선했으며, 유사 비트레이트 조건에서 SSIM 0.723에서 0.741로, PSNR 17.90 dB에서 18.10 dB로 향상되었다.

한계도 분명하다. 제안 모델은 동일 quality index에서 비트레이트가 40% 이상 증가하며, PSNR 곡선이 비단조적이다. 또한 CBAM 삽입 위치(인코더/디코더)와 β , γ 에 대한 격자 탐색은 수행했으나, CBAM·Edge Loss·TV

Loss를 하나씩 제거하는 구성 요소별 절제 실험(ablation study)은 완료하지 못했다. 따라서 관측된 개선이 세 요소 중 어디에서 비롯되었는지는 아직 특정할 수 없다.

향후 과제로는 다섯 가지를 계획하고 있다. 첫째, 압축률에 비해 β 와 γ 의 스케일을 동적으로 조정하는 함수를 도입함으로써, 중간 비트레이트 구간에서 나타나는 PSNR 역전을 해소하는 것이다. 둘째, quality index별로 CompressAI가 규정하는 λ 를 적용해 재학습하는 것이다. 셋째, 체커보드 아티팩트의 근본 원인으로 의심되는 디코더의 전치 합성곱(ConvTranspose2d)을 Upsample와 Conv2d 조합으로 교체해 구조적으로 해결하고, 이를 통해 TV Loss 의존도를 낮추는 것이다. 넷째, 구성 요소별 절제 실험을 통해 각 기여를 분리 검증하는 것이다. 다섯째, 과평활화 완화를 위해 MSE 대신 L1 손실을 사용하는 방안을 검토하는 것이다.

참고 문헌

- [1] J. Ballé, D. Minnen, S. Singh, S. J. Hwang, N. Johnston, "Variational Image Compression with a Scale Hyperprior", ICLR, 2018.05.
- [2] K. L. Cheng, Y. Xie, Q. Chen, "Optimizing Image Compression via Joint Learning with Denoising", ECCV, 2022.10.
- [3] B. Brummer, C. De Vleeschouwer, "Learning Joint Denoising, Demosaicing, and Compression from the Raw Natural Image Noise Dataset", arXiv:2501.08924, 2025.01.
- [4] L. Zhang, Q. Zhou, R. Liu, L. Huyan, J. Liu, Y. Zhang, "Noise-Aware Hybrid Compression of Deep Models with Zero-Shot Denoising and Failure Prediction", Applied Sciences, vol. 15, no. 24, 12882, 2025.12.
- [5] S. Woo, J. Park, J.-Y. Lee, I. S. Kweon, "CBAM: Convolutional Block Attention Module", ECCV, 2018.09.
- [6] C. Wei, W. Wang, W. Yang, J. Liu, "Deep Retinex Decomposition for Low-Light Enhancement", BMVC, 2018.09.

- [7] J. Bégaint, F. Racapé, S. Feltman, A. Pushparaja, “CompressAI: a PyTorch library and evaluation platform for end-to-end compression research”, arXiv:2011.03029, 2020.11.
- [8] J. Liu, H. Sun, J. Katto, “Learned Image Compression with Mixed Transformer-CNN Architectures”, CVPR, 2023.06.
- [9] S. Cai, L. Chen, S. Zhong, L. Yan, J. Zhou, X. Zou, “Make Lossy Compression Meaningful for Low-Light Images”, AAAI, 2024.02.